UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i INF2220 — Algoritmer og datastrukturer

Eksamensdag: 12. desember 2014

Tid for eksamen: 14.30-18.30

Oppgavesettet er på 13 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Alle trykte eller skrevne

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Innhold

1	Tidskompleksitet (vekt 10%)	side 2
2	Uttrykkstrær og rekursjon (vekt 11%)	side 2
3	Grafer (vekt 14%)	side 5
4	Produktsum (vekt 13%)	side 8
5	Tekstalgoritmer (vekt 10%)	side 9
6	Internettsøkeprogrammer (vekt 26%)	side 9
7	Algoritmer og kompleksitet (vekt 16%)	side 11

Generelle råd:

- Skriv **leselig** (uleselige svar er alltid feil ...)
- Husk å **begrunne** svar og hold kommentarene dine korte og presise.
- Hvis du bruker kjente datastrukturer som (list, set, map, binær-tre) trenger du ikke forklare hvordan de fungerer. Generelt: hvis du bruker abstrakte datatyper fra biblioteket kan du bruke disse uten å forklare hva de gjør.
- Hvis skriver pseudokode, må den være detaljert. Det må komme klart fram hvilken datastruktur du bruker, hva initialiseringen består av og hva hovedløkkene gjør.
- Du skal bruke Java.
- **Vekten** til en oppgave indikerer vanskelighetsgraden og tidsbruken du bør bruke på den oppgaven. Dette kan være greit å benytte for å disponere tiden best mulig.

Lykke til!

Ingrid Chieh Yu, Dino Karabeg og Arne Maus

(Fortsettes på side 2.)

Oppgave 1 Tidskompleksitet (vekt 10%)

Hva er worst case-tidskompleksiteten (big O) til følgende kodesegmenter:

1a (vekt 5%)

```
int x = 0;
for (int i = n; i >= 1; i = i/2){
   for (int j = 1; j <= i; j++){
      x = x + i + j;
   }
}</pre>
```

Solution:

O(n)

The inner loop run with halved sizes each time summing up to opprox. 2n

1b (vekt 5%)

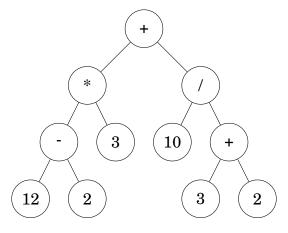
```
int x = 0;
for (int j = 1; j <= n; j++){
   for (int i = n; i >= j; i = i/2){
        x = x + i + j;
   }
}
```

Solution:

O(n log n)

The inner loop runs an average of $\log(n/2)$ which is the same as $\log n - \log 2$. Where the smaller expression is removed.

Oppgave 2 Uttrykkstrær og rekursjon (vekt 11%)



Figur 1

Figur 1 viser et *uttrykkstre*. Et uttyksetre er en entydig måte å representere et regnestykke, der verdien til en node tilsvarer enten resultatet av operanden den innholder utført på nodens to barn eller verdien til tallet i noden.

2a Evaluering av uttrykkstreet (vekt 2%)

Evaluer uttrykkstreet i Fig. 1, og skriv resultatet. Solution:

32

2b Rekursjon (vekt 7%)

Implementer en rekursiv metode med signaturen public void evalTree (BinTree t) som skal evaluere et uttrykstre. Programmet skal kombinere klassene MyStack og BinTree med postorder traversering av trær. Du kan anta at klassen metoden ligger i har initialisert en instanse av klassen MyStack med tilstrekkelig størrelse med navn stack.

```
public class MyStack {
   private int maxSize;
   private int[] stackArray;
   private int top;
   public MyStack(int s) {
      maxSize = s;
      stackArray = new int[maxSize];
      top = -1;
   public void push(int j) {
      stackArray[++top] = j;
   public long pop() {
      return stackArray[top --];
}
class BinTree {
   String value;
   BinTree left;
   BinTree right;
```

En stack er en implementasjon av konseptet *LIFO datahåndtering*. Se for deg en stabel med tallerkener der du enten setter en tallerken på toppen av stabelen med *push* eller henter en tallerken fra toppen av stabelen med *pop*. Verdiene som skal lagres i treet er representert med strenger og inneholder enten en av de aritmetiske operatorene "+", "-", "*" og "/" eller en tallverdi. Programmet skal fungere som følger: Når en node inneholder en streng med et tall så skal integerverdien til strengen pushes på stacken. Når en node inneholder en operand så skal man først evalure verdien til de to barna før man poper høyre- og venstrebarnets verdier av stacken og utfører operatoren på de to operandene.

Resultatet av verdien skal pushes på stacken. Når programmet har kjørt ferdig skal stacken kun inneholde verdien uttrykkstreet evaluerer til. Solution:

```
class EvalClass {
   private MyStack stack; //the stack is initalized somewhere else
   public void evalTree(BinTree t){
      int op1;
      int op2;
      int result;
      if (t == null) {
         return;
      evalTree(t.left);
      evalTree(t.right);
      if (value.equals("+")) {
         op2 = stack.pop();
         op1 = stack.pop();
         result = op1 + op2;
      else if (value.equals("-")) {
         op2 = stack.pop();
         op1 = stack.pop();
         result = op1 - op2;
      else if (value.equals("*")) {
         op2 = stack.pop();
         op1 = stack.pop();
         result = op1 * op2;
      else if (value.equals("/")) {
         op2 = stack.pop();
         op1 = stack.pop();
         result = op1 / op2;
      else {
         result = Integer.parseInt(t.value));
      stack.push(result);
   }
}
```

2c Operasjoner på stack (vekt 2%)

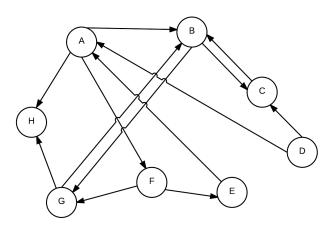
Skriv de 10 første push- og pop-operasjonene som resulterer når programmet ditt er anvendt på uttrykkstreet i Fig. 1. (F.eks, push 4; pop 4; push 7; ...)
Solution:

push 12; push 2; pop 2; pop 12; push 10; push 3; pop 3; pop 10; push 30; push 10

Oppgave 3 Grafer (vekt 14%)

3a Sterkt sammenhengede komponenter (SCCs) (vekt 7%)

Gitt en rettet graf med noder A, \ldots, H som vist i Figur 2.



Figur 2: En rettet graf

- 1. Hvilke sterkt sammenhengende komponenter (Strongly Connected Components (SCCs)) har grafen i Figur 2? Du skal illustrere hvordan SCCs er funnet algoritmisk ved å vise trinnene i algoritmen.
- 2. Gitt en vilkårlig rettet graf G, la G' være en rettet graf der hver node i G' representerer en SCC av G. For nodene u og v i G' finnes det en kant (u,v) hvis det finnes en kant i G som forbinder SCCene som tilsvarer u og v. Kan G' sorteres topologisk? Begrunn kort.

Solution:

For correction:

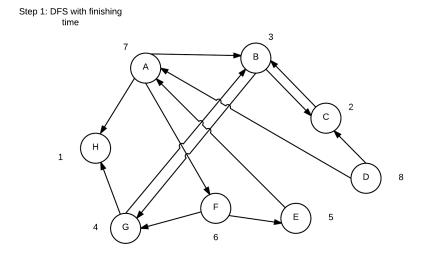
4 points for 3a.1 and 3 points for 3a.2

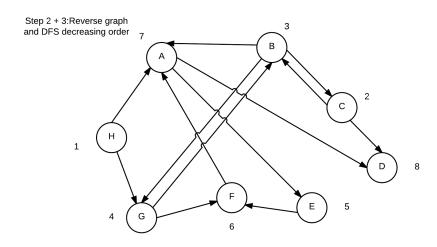
- 1. see Figure 3
- 2. Yes. If there were any cycles in the graph of strongly connected components, then all the components on the cycle would actually be one strongly connected component. So *G'* must be a DAG and all DAGs can be topologically sorted.

3b Korteste vei (vekt 7%)

Korteste vei-en til alle-problemet (single-source shortest path problem) handler om å finne korteste vei fra en startnode til alle andre noder i en graf. Det kan være mer enn en vei som har den minste kosten. For eksempel, for grafen G i Figur 4 med startnode A, har vi 3 stier fra A til E med kost 4 ($\langle A, C, E \rangle$, $\langle A, D, C, E \rangle$ og $\langle A, B, E \rangle$).

(Fortsettes på side 6.)





SCC: { (D), (F,E,A), (C, B, G), (H)}

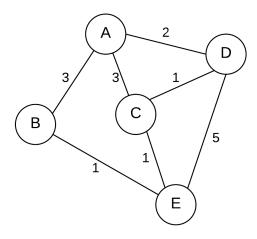
Figur 3: Solution for SCC oppg 1

Implementer en algoritme som i tillegg til å finne korteste vei fra en gitt startnode s til alle andre noder w også beregner antall korteste veier fra s til w. La int num_paths være den variabelen i klassen Vertex som inneholder denne informasjonen. Du kan anta at grafen ikke har negative kanter.

Solution:

The solution is a modification of Dijkstra. There are 3 considerations:

- num_paths to s is 1.
- when finding a better path to w through v: the num_paths to w is the num_paths to v.
- when finding an equally lengthy path to w through v: the num_paths to w is increased by num_paths to v.



Figur 4: Grafen G

The pseudokode is taken from the Weiss text book used in this course.

```
void dijkstra_with_num_path(Vertex s) {
  for each Vertex v {
    v.dist = INFINITY;
    v.known = false;
 s.dist = 0;
  s.num_paths = 1; //new code
    Vertex v = smallest unknown distance vertex;
    if(v == NOT_A_VERTEX)
       break;
    v.known = true;
    for each Vertex w adjacent to v
       if(!w.known){
          if(v.dist + cvw< w.dist){</pre>
            //update w
            decrease(w.dist to v.dist + cvw);
            w.path = v;
            w.num_paths = v.num_paths // new code
          else if (v.dist + cvw == w.dist) //new code
            w.num_paths +=v.num_paths;
       }
   }
}
```

Oppgave 4 Produktsum (vekt 13%)

Gitt en liste av n heltall, v_1, \ldots, v_n , er produktsummen av listen den største sum man kan lage ved å multiplisere tilstøtende elementer i listen. Hvert element kan maksimalt bli matchet med en av sine naboer. For eksempel, for listen 1, 2, 3, 1 er produktsummen $8 \ (= 1 + (2 \times 3) + 1)$ og for listen 2, 2, 1, 3, 2, 1, 2, 2, 1, 2 er produktsummen $19 \ (= (2 \times 2) + 1 + (3 \times 2) + 1 + (2 \times 2) + 1 + 2)$.

4a Optimalisering (vekt 6%)

Gitt en liste av n heltall for $n \geq 2$. Hva er den optimale produktsummen OPT(j) for de første j elementene i listen? Du skal altså finne ut hva OPT(j) gir for $j \in \{0, 1, ..., n\}$.

```
Solution:
```

```
OPT(0) = 0

OPT(1) = v_1

OPT(j) = max(OPT(j-1) + v_j, OPT(j-2) + (v_j \times v_{j-1})) if j \ge 2
```

For correction:

- 1 point for OPT(0)
- 1 point for OPT(1)
- 4 points for OPT(j) where $j \Rightarrow 2$

4b Dynamisk programmering (vekt 7%)

Gi en dynamisk programmeringsløsning for dette problemet. Implementer metoden prodSum som returnerer produktetsummen av de j første elementene av en liste v:

```
int prodSum(int [] v, int j) {
... //din kode
}
```

Metoden trenger kun å returnere selve produktsummen. Solution:

```
int prodSum (int [] v, j){
  if(j==0) return 0;

int [] OPT = new int [j+1];
  OPT[0] = 0;
  OPT[1] = v[1];
  if (j >= 2) {
    for int k = 2 to j
        OPT[k] = max ( OPT[k-1] + v[k], OPT[k-2] + v[k] * v[k-1]);
  }
  return OPT[j]
}
```

Oppgave 5 Tekstalgoritmer (vekt 10%)

5a Boyer Moore (vekt 4%)

Beregn good suffix shift til nålen:

SUSSENUSS

Solution:

0	!S	2
1	!SS	6
2	!USS	8
3	!NUSS	5
4	!ENUSS	8
5	!SENUSS	8
6	!SSENUSS	8
7	!USSENUSS	8
8	!SUSSENUSS	8

5b Huffman-koding (vekt 6%)

Gitt følgende tekst:

bibbidi-bobbidi-boo

- 1. Vis frekvenstabellen og Huffman-treet for setningen.
- 2. Hva er Huffman-koden for de ulike tegnene?

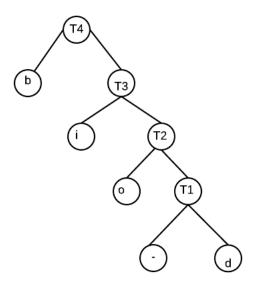
Solution:

Chars	Frequency	Coding
_	2	1110
b	7	0
d	2	1111
i	5	10
0	3	110

Oppgave 6 Internettsøkeprogrammer (vekt 26%)

Et problem for internettsøkeprogrammer som Google, Bing og DuckDuckGo, er at et søk kan generere millioner av svar (søker du på 'Obama' i Google får du 595 millioner svar!). Disse svarene er mer eller mindre relevante for den som søkte. Vedkommende søker har heller aldri muligheter for å se på alt. Hen vil se på det mest relevante. Hver side (av de mange millioner treff) kan vi anta har en

(Fortsettes på side 10.)



Figur 5: Solution for 5b. 1

relevans-score, som er et heltall som er slik at jo større dette tallet er, desto mer relevant er vedkommende side.

Vi skal hjelpe DuckDuckGo til å skrive, og senere i oppgave 6c parallellisere, løsningen på dette problemet. Anta at du har n svar og at relevans-scoren ligger lagret i heltallsarrayen a[0..n-1]. En triviell sekvensiell løsning i Java er å bruke Javas innebygde sorterings algoritme (Arrays.sort(int [] a)), sortere hele arrayen og så plukke ut de 50 største tallene. Men dette tar alt for lang tid. En klart raskere algoritme er følgende:

- 1. Vi antar først at de 50 tallene er i a[0..49] er de største og innstikksorterer dette området i $a[\]$ i synkende rekkefølge (du må trivielt skrive om vanlig innstikksortering til å sortere i synkende rekkefølge).
- 2. Da vet vi at det minste tallet av de 50 første tallene i $a[\]$ da ligger i a[49]. Dette tallet sammenligner vi etter tur med hvert element i a[50..n-1]. Finner vi element a[j] > a[49], så :
 - a. Bytt $a[49] \mod a[j]$
 - b. Innstikk-sorter det nye elementet inn i a[0..48] i synkende rekkefølge.
- 3. Når pkt. 2 er ferdig, ligger de 50 største tallene i a[0..49] og ingen av øvrige tallene er overskrevet eller ødelagt.

6a Sortering i synkende rekkefølge (vekt 6%)

Skriv først en sekvensiell metode:

void baklengsInnstikkSortering(int[] a, int fra, int til) som sorterere området a[fra..til] i en større array a[] i synkende rekkefølge.

(Fortsettes på side 11.)

6b Finn mest relevante svar (vekt 10%)

Skriv en sekvensiell metode:

```
void finn50Største(int[] a) {..<din Java-kode her>..}
```

som implementerer algoritmen som skisseres ovenfor og som kaller først metoden fra oppgave 6a. For at du skal få bedre enn C på denne deloppgaven, må du gjøre noe annet enn bare å kalle metoden fra oppgave 6a hver gang vi har fått et nytt, større element i a[49].

Skriv en ny metode for dette enklere tilfellet hvor bare a[49] muligens er feilplassert i a[0..49]

6c Parallellitet (vekt 10%)

Skriv med ord (ikke skriv kode) hvordan du ville parallellisere dette problemet med tråder hvis du har en multikjerne maskin med k kjerner. Svar da minst på følgende spørsmål:

- Hvordan ville du dele data mellom de trådene du starter?
- Når og hvordan vil du synkronisere de trådene du har (både main-tråden og de trådene du startet for å få beregne svaret for dette problemet)?
- Hvordan vil du sette sammen beregningene fra trådene til et samlet svar på problemet; det å finne de 50 største tallene i en meget stor array a[0..n]?

(For n = 100 millioner er den sekvensielle algoritmen ca. 70 ganger raskere og den parallelle algoritmen med 8 kjerner, 273 ganger raskere enn Arrays.sort).

Oppgave 7 Algoritmer og kompleksitet (vekt 16%)

For hver av påstandene under: svar på hvorvidt den er *sann* eller *usann* og gi en kort begrunnelse på svaret ditt der du skal vise forståelse for konseptene som er innvolvert.

7a (vekt 2%)

Vi vet at vi kan finne et element i en liste med n elementer på $O(\log n)$ tid ved å holde listen sortert og gjøre et binærsøk. Vi vet også at vi kan sortere n elementer på $O(n \log n)$ tid. Men vi kan aldri vite hvorvidt dette er den ideelle ytelsen vi kan oppnå og hvorvidt det er mulige å lage bedre algoritmer. Solution:

False - Under certain assumptions - such as that we can only acquire information by doing comparisons (and learning one bit of information at a time) - we can compute the corresponding "lower bounds" for searching and sorting, and thus prove that our algorithms are "optimal".

7b (vekt 2%)

B-trær tillater oss å ha en mer effektiv bruk av lagringsplass, men det er ingen forskjell i kjøretiden til b-trær sammenlignet med andre balanserte søketrær. Solution:

False - while B-tree operations are still O(log n), they dramatically reduce the actual running time by minimizing the number of disk accesses.

7c (vekt 2%)

Man kan gjøre søk mer effektivt med hashing enn det som er mulig med binærsøk og binære søketrær.

Solution:

True (also maybe with explanation can work); search by hashing is constant time - but in the average-case sense. Most hashing strategies degenerate to a linear performance or worse for a worst-case sequence of operations.

7d (vekt 2%)

Dobbel hashing er brukt for å unngå sekundære kollisjoner (secondary clustering).

Solution:

True - Quadratic probing leaves us with the problem of secondary clustering. Double hashing avoids secondary clustering by using a whole new hashing function in case of collision.

7e (vekt 2%)

Utvidbar hashing løser problemet med kollisjoner ved å lagre verider i en lenket liste.

Solution:

False - Extendible hashing avoids collisions by using the key to compute the disk address and then do a lookup in a smaller space.

7f (vekt 2%)

Ved å representere problemer som formelle språk oppnår vi et systematisk og enhetlig syn på problemer og algoritmer.

Solution:

True - By representing problems as formal languages we can put all problems into a single large set; then divide this set into classes of problems, and create a "map of all problems". By "putting a problem on the map" (estimating the complexity by placing a problem into a complexity class) we can know what algorithm-design approaches might be suitable. (NP-complete problems for ex. are solved with different techniques than problems in P.)

7g (vekt 2%)

Det er viktig å kunne skille mellom problemene som har løsninger i polynomiell tid og de som ikke har det.

Solution:

True - Many practically important problems can only be solved by "exhaustive search" algorithms, which - although in principle correct - may require centuries, or practically forever, to compute an answer. We modeled this distinction by the class P for "efficiently solvable", and NP-complete and other classes for not efficiently solvable or intractable.

7h (vekt 2%)

Alan Turing lagde den første kommersielle datamaskinen, kalt Turingmaskinen. Solution:

False - The Turing Machine is an abstract or mathematical model of the real-world notions solution", "algorithm" and "computer".

Oppgave 4 inf2220 h2014 (tid: ca. 30 % av totalen)

Et problem for internettsøkeprogrammer som Google, Bing og DuckDuckGo, er at et søk kan generere millioner av svar (søker du på 'Obama' i Google får du 595 millioner svar!). Disse svarene er mer eller mindre relevante for den som søkte. Vedkommende søker har heller aldri muligheter for å se på alt. Hen vil se på det mest relevante. Hver side (av de mange millionene treff) kan vi anta har en relevans-score, som er et heltall som er slik at jo større dette tallet er, desto mer relevant er vedkommende side.

Vi skal hjelpe DuckDuckGo til å skrive, og senere i pkt c. parallellisere, løsningen på dette problemet. Anta at du har n svar og at relevans-scoren ligger lagret i heltallsarrayen a[0..n-1]. En triviell sekvensiell løsning i Java er å bruke Javas innebygde sorterings algoritme (Arrays.sort(int [] a)), sortere hele arrayen og så plukke ut de 50 største tallene. Men dette tar alt for lang tid. En klart raskere algoritme er følgende:

- 1. Vi antar først at de 50 tallene er i a[0..49] er de største og innstikksorterer dette området i a[] i synkende rekkefølge (du må trivielt skrive om vanlig innstikksortering til å sortere i synkende rekkefølge).
- 2. Da vet vi at det minste tallet av de 50 første tallene i a[] da ligger i a[49]. Dette tallet sammenligner vi etter tur med hvert element i a[50..n-1]. Finner vi element a[j] > a[49], så:
 - a. Bytt a[49] med a[j]
 - b. Innstikk-sorter det nye elementet inn i a[0..48] i synkende rekkefølge.
- 3. Når pkt. 2 er ferdig, ligger de 50 største tallene i a[0..49] og ingen av øvrige tallene er overskrevet eller ødelagt.
- a) Skriv først en sekvensiell metode (10%):

```
void baklengsInnstikkSortering(int[] a, int fra, int til)
som sorterere området a[fra..til] i en større array a[] i synkende rekkefølge.
```

Løsning – eneste endring fra vanlig innstikksortering er ulikhetstegnet i while-løkka er snudd (men å finne det er ikke nødvendigvis trivielt):

```
void baklengsInnstikkSortering(int[] a, int fra, int til) {
    int i , t ;
    for (int k = fra ; k < til; k++) {
        t = a[k+1];
        i = k;
        while (i >= fra && a[i] < t) {
            a[i+1] = a[i];
            i--;
        }
        a[i+1] = t;
    }
} // end baklengsInnstikkSortering</pre>
```

b) Skriv en sekvensiell metode (10%):

void finn50Største (int[] a) { ..<din Java-kode her>..}

som implementerer algoritmen som skisseres ovenfor og som kaller først metoden fra pkt.a i oppgaven. For at du skal få bedre enn C på denne deloppgaven må du gjøre noe annet enn bare å kalle metoden fra pkt.a hver gang vi har fått et nytt, større element i a[49]. Skriv en ny metode for dette enklere tilfellet hvor bare a[49] muligens er feilplassert i a[0..49].

```
void finn50Største (int [] a, int fra, int til) {
 baklengsInnstikkSortering(a,fra, fra+49);
 int ind49= 49+fra, nr49 = a[ind49], i , t;
  for (i = ind49+1; i <= til; i++) {
       if (a[i] > nr49) {
             // swap a[49] og a[i]
             a[ind49] = a[i];
             a[i] = nr49;
             settInnStørre (a,fra,ind49, a[ind49]);
             nr49=a[ind49];
       }
 }//end finn50Største
  void settInnStørre(int []a, int fra, int plass, int nyVal){
       int
            t = a[plass];
       while (plass > fra && nyVal > a[plass-1]) {
                           a[plass] = a[plass-1] ;
             plass--;
       }
       a[plass] = nyVal;
 } // end settInnStørre
```

- c) 10%: Skriv med ord (ikke skriv kode) hvordan du ville parallellisere dette problemet med tråder hvis du har en multikjerne maskin med k kjerner. Svar da minst på følgende spørsmål:
 - Hvordan ville du dele data mellom de trådene du starter?

Svar: Antar at n >= k*50. Starter da k tråder. Deler så a[] i k like store deler. En del til hver av de k trådene du starter. Husk at hvis ikke n%k == 0, så må siste del være litt større enn de andre delene. Parametrisérer metoden fra den sekvensielle løsningen slik at de også kan nyttes av den parallelle koden. Se vedlagte program.

- Når og hvordan vil du synkronisere de trådene du har (både main-tråden og de trådene du startet for å få beregne svaret for dette problemet).

Svar: a) Main tråden må først legge seg på å vente at alle de trådene som den har startet, terminerer – f.eks med join().

- b) De k trådene må etter at de selv har funnet de 50 største i sin del av arrayen, vente med f.eks en CyclicBarrier til alle de k trådene er ferdig med dette. Det kan være greit (men ikke nødvendig) at hver tråd kopierer sine 50 største ned i en mindre int [] b = new int[50*k]; Dette fordi det å finne de 50 største av de 50*k største, lettes gjøres av én av disse trådene (sekvensiell kode) f.eks av tråd 0. Se vedlagt program.
 - Hvordan vil du sette sammen beregningene fra trådene til et samlet svar på problemet ; det å finne de 50 største tallene i en meget stor array a[0..n].

Svar: Når tråd 0 vet at alle de andre trådene har gjort jobben sin og lagt sine 50 største ned i b[] på 'sine 50 plasser', bare innstikksorterer tråd 0 de 50*k tallene sor å finne de 50 største.

(For n = 100 millioner er den sekvensielle algoritmen ca. 70 ganger raskere og den parallelle algoritmen med 8 kjerner, 273 ganger raskere enn Arrays.sort).